

Analisi e Credit Scoring del Rischio di Credito

1. Executive Summary

L'obiettivo del seguente progetto è di sviluppare un modello capace di identificare e classificare i clienti ad alto rischio di credito usando informazioni demografiche e finanziarie.

Il rischio di credito si riferisce alla possibilità che una controparte, come un cliente o un fornitore, non sia in grado di adempiere ai propri obblighi di pagamento nei confronti dell'organizzazione, esso può manifestarsi in vari modi: dal ritardo nei pagamenti al totale fallimento dell'obbligo e la gestione del rischio è fondamentale per la salute finanziaria di una società in quanto rappresenta una delle principali minacce per la continuità operativa delle imprese.

Per individuare i clienti ad alto rischio di credito è stato stimato un modello di regressione logistica, la scelta del seguente modello è stata dettata non soltanto tenendo conto delle capacità predittive ma anche considerando l'interpretabilità che il modello offre al contrario di modelli Black-Box.

Sono stati utilizzati due strumenti per il seguente lavoro: Python per la parte di modellistica e Power BI per la creazione di una dashboard utile alla visualizzazione dei risultati ottenuti.

Il modello finale presenta un buon valore di AUC, uguale a 0.8, mostrando un miglioramento rispetto al modello iniziale, un miglioramento che riguarda anche le principali metriche utilizzate per la valutazione del modello come Precision, Recall e F1-score. Le probabilità finali del modello sono state utilizzate per costruire un credit score tramite il quale sono stati divisi i clienti in tre categorie di rischio: basso, medio e alto.

L'utilità del modello va oltre la stima della probabilità che un cliente risulti affidabile o rischioso, esso può supportare il processo decisionale nella concessione del credito, aiuta a ridurre perdite economiche legate ai default e permette una valutazione più veloce e standardizzata dei clienti; inoltre la segmentazione Low/Medium/High Risk facilita la priorità di controllo sui clienti più rischiosi e può essere integrata in dashboard e sistemi di monitoraggio.

2. Descrizione del Dataset

I dati utilizzati provengono da UCI Machine Learning Repository ed è noto come German Credit Dataset, il dataset è pubblico e molto utilizzato per problemi di credit scoring e classificazione binaria.

Il dataset è strutturato in 20 variabili indipendenti più una variabile target con un totale di 1000 osservazioni, sono presenti variabili sia numeriche che categoriche che coprono caratteristiche sia finanziarie che personali dei clienti.

Il target binario è la variabile `credit_risk` e rappresenta l'affidabilità creditizia del cliente divisa in good credit e bad credit, distribuiti al 70% good e 30% bad, mentre le principali variabili esplicative sono riportate nella Tabella 1.

Variabile	Spiegazione	Utilità
amount	Importo del credito richiesto	Possibile indicatore di esposizione finanziaria
duration	Durata del prestito	Prestiti più lunghi possono implicare rischio maggiore
savings	Disponibilità di risparmi del cliente	Possibile indicatore di stabilità economica
status	Situazione del conto corrente	Utile per valutare liquidità e affidabilità finanziaria
age	Età del cliente	Possibile relazione con stabilità lavorativa/economica
employment_duration	Anzianità lavorativa	Indicatore di continuità reddituale

Tabella 1- Spiegazione variabili esplicative

L'insieme di queste variabili permette di condurre uno studio sul fenomeno ma il dataset non è esente da problemi, il numero di osservazioni è basso (1000), ciò non permette una stima molto accurata del modello, poi mancano informazioni finanziarie avanzate, questa mancanza potrebbe portare ad ignorare aspetti fondamentali che influiscono sul rischio di credito e unito al fatto che i dati non sono recenti è possibile una limitata generalizzazione a contesti bancari moderni, un punto di forza però è che le variabili presenti sono di facile lettura ed interpretazione, ciò può essere utile per osservare aspetti più sociali o demografici che influiscono sul rischio senza affidarsi esclusivamente ad aspetti tecnici.

Un ultimo problema, seppur minore, è lo sbilanciamento delle classi del target, come già scritto è presente una proporzione 70/30 a favore della classe Good, seppur non sia una situazione ideale per stimare il modello come lo sarebbe l'equilibrio tra le due questo sbilanciamento non è stato ritenuto problematico e quindi non sono state effettuate operazioni per sistemare questo aspetto.

3. Data Preparation e Preprocessing

3.1 Analisi descrittiva

Come prima operazione sui dati, è stata fatta un'analisi sulle principali variabili presenti, si nota come l'importo medio del credito sia di 2985 marchi per i clienti good e 3938 marchi per i clienti bad, una differenza che in euro e tenendo conto dell'inflazione corrisponde a circa 900 euro, anche la durata del prestito è differente, i clienti ad alto rischio chiedono prestiti con una durata media più lunga di 5 mesi (24 mesi contro 19), non si osservano differenze importanti riguardo l'età media dei clienti che passa dai 33 anni dei clienti bad ai 36 dei clienti good.

Analizzando invece l'importo richiesto, senza divisione tra clienti buoni e cattivi, è mostrato nel Grafico 1 come la distribuzione sia fortemente asimmetrica verso sinistra con la maggior parte degli importi inferiori a 5000 marchi e una lunga coda che si prolunga fino a 17500 marchi, il grafico mostra forse uno dei punti deboli del dataset che considera solo piccoli prestiti escludendo importi più rischiosi ma che comunque possono essere considerati comuni, per esempio le richieste di mutuo.




Grafico 1- Distribuzione di frequenza degli importi concessi

Analizzando le variabili categoriche si osserva un risultato interessante riguardo i savings, con un gap sempre più alto a favore dei clienti a basso rischio all'aumentare dei risparmi, l'ultima classe della variabile (risparmi superiori a 1000 marchi) è distribuita per 87,5% clienti good e 12,5% clienti bad, un andamento simile ma meno accentuato è presente anche per le classi della disponibilità sul conto corrente, come ulteriore conferma che i clienti a basso rischio sono quelli con una base patrimoniale più solida si guarda anche il tipo di abitazione, con una forbice più ampia osservata tra chi è proprietario dell'abitazione.

3.2 Preprocessing

Prima di poter stimare il modello è stato necessario fare dei controlli sui dati e sui possibili problemi ad essi legati, per iniziare è stato effettuato un controllo sui valori mancanti e fortunatamente non sono stati riscontrati problemi a riguardo. Successivamente, vista la presenza di molte variabili categoriche, è stato applicato ai dati l'one-hot encoding, ossia la sostituzione di una variabile factor con più variabili binarie che indicano la presenza o l'assenza della modalità, i vantaggi di usare questa tecnica consistono nell'eliminare l'ordinalità di alcune variabili, fornire una rappresentazione più dettagliata delle variabili e migliorare così le

performance del modello e infine la compatibilità con algoritmi che richiedono come input solo variabili numeriche.

Come ultimo passaggio prima di stimare il modello il dataset è stato diviso in 2 dataset differenti, uno di train e uno di test, questa divisione è necessaria per validare il modello dopo la stima e valutarne l'affidabilità, la divisione è stata effettuata tramite uno stratified split per mantenere invariata la distribuzione delle due classi; un problema riguardo lo split è legato all'esiguo numero di osservazioni, il sacrificio di alcune di esse per la creazione del dataset di test può influire negativamente sulla stima del modello, in alternativa si sarebbe potuto usare una tecnica di internal validation come la cross validation.

Stimato il primo modello, quest'ultimo è stato usato per osservare variabili affette da multicollinearità e outlier. Per la multicollinearità è stato calcolato il VIF e i valori più alti appartenevano alle variabili: `foreign_worker_yes`, `purpose_domestic_appliances` e `other_debtors_none`, le tre variabili sono state escluse dal modello, oltre a queste sono state trovate altre variabili con VIF alto ma è stato deciso di tenerle sia per l'importanza che potrebbero avere nel modello finale sia per il fatto che il valore del VIF si abbassa togliendo le 3 variabili più affette da multicollinearità; gli outlier sono stati identificati con l'IQR e ciò ha portato all'esclusione di 138 osservazioni.

4. Modeling e Valutazione del Modello

4.1 Stima e validazione del modello

Risolti i problemi di multicollinearità e degli outlier è stato stimato il modello finale, come già scritto prima la scelta del modello è ricaduta su un modello di regressione logistica, questo perché il modello di regressione logistica ha delle buone performance di adattamento ai dati ma offre anche un'interpretabilità che altri modelli non offrono, la presenza di coefficienti e di un p-value per ogni variabile permette non solo di classificare i clienti ma anche di indagare quali variabili sono significative e in che modo influiscono sulla probabilità finale.

Dopo aver allenato il modello sul dataset di train sono state ricavate alcune metriche applicandolo al dataset di test, come prima cosa si guarda il valore dell'AUC, ottimo indicatore della bontà di un modello e del suo potere discriminante, il risultato finale è AUC uguale a 0.80, ossia il modello ha un buon adattamento ed è robusto, il valore è stato ottenuto anche grazie alle precedenti operazioni di preprocessing che hanno permesso di aumentare l'AUC da 0.75 a 0.80.

Prima di valutare le metriche del modello si è proceduto col tuning della soglia, di default uguale a 0.5, per migliorare i risultati della classificazione, l'andamento delle metriche al variare della soglia è commentabile dal Grafico 2




Grafico 2- Variare delle performance delle metriche al variare della scelta della soglia

Dal Grafico 2 si osserva come la scelta migliore per la soglia sia tra lo 0.65 e lo 0.70, questo perché è il range di valori che porta a performance migliori delle 4 metriche considerate.

4.2 Risultati del modello

Stimato il modello si ottiene la seguente matrice di confusione:

Actual Risk \ Predicted Risk	Predicted Risk	
	Bad	Good
Bad	32	14
Good	22	105

L'accuracy è 0.79, un risultato buono ma non eccezionale, è utile a dare una visione generale della performance ma può essere fuorviante per dataset sbilanciati, con il 70% di clienti good un modello banale avrebbe un'accuracy pari a 0.70 senza però discriminare tra le due classi.

Come metrica principale dell'analisi si considera l'F1-Score, ossia la media armonica tra Precision e Recall (o Sensitivity), dove la Precision misura quanto sono affidabili le previsioni positive del modello e la Recall misura la capacità del modello di identificare correttamente i clienti positivi. Un bilanciamento tra le due permette di migliorare l'affidabilità di classificazione di clienti positivi e di ridurre di classificare clienti rischiosi come positivi.

L'F1-Score finale è di 0.85 quindi il modello identifica molto bene clienti buoni, maggiori difficoltà si riscontrano nell'individuare clienti rischiosi dove l'F1-Score è pari a 0.63, questo

risultato era prevedibile visto lo sbilanciamento delle classi e sicuramente concentrarsi maggiormente su clienti rischiosi rappresenta un futuro step di miglioramento per l'analisi.

4.3 Interpretazione coefficienti

Una volta stimato il modello finale si valuta la significatività delle variabili, in totale le variabili risultate significative sono 11 sulle 49 di partenza (tutte le variabili categoriche sono state dummizzate, ecco perché l'aumento da 20 a 49) e sono: duration, status_... ≥ 200 DM, status_no checking account, credit_history_critical account, credit_history_delay in paying off in the past, credit_history_existing credits paid back duly till now, purpose_retraining, savings_... ≥ 1000 DM, personal_status_sex_male : single, other_debtors_guarantor, foreign_worker_yes. Le variabili associate ad un cattivo cliente hanno segno negativo poiché i clienti risk sono codificati con lo 0 e i coefficienti negativi spingono la probabilità verso lo 0; le uniche variabili con coefficiente negativo sono: duration, purpose_retraining e foreign workers_yes, da questo si deduce che i clienti più rischiosi chiedono prestiti lunghi, influisce sul rischio anche se un cliente è un lavoratore straniero e infine se il motivo del prestito è per una riqualificazione professionale o un corso di formazione, queste caratteristiche possono descrivere clienti in fase di instabilità lavorativa e un reddito temporaneamente debole, questa interpretazione è da valutare con cautela, lo scopo del lavoro non è giungere ad una conclusione sociale forte e questi risultati possono riflettere un bias storico e demografico presente nel dataset originale che non implica una reale relazione causale.

Questi risultati possono anche evidenziare un'importante sfida del credit risk modeling: bilanciare le performance predittive del modello con equità e considerazioni etiche.

5. Credit Scoring e Segmentazione del Rischio

Per permettere una maggiore interpretabilità la probabilità finale del modello è stata trasformata in un credit score che va da 0 a 1000, punteggi alti indicano clienti affidabili mentre punteggi più bassi sono associati a clienti più rischiosi.

Le fasce di rischio sono state definite utilizzando soglie di punteggio al fine di creare un framework di classificazione dei clienti semplice e interpretabile; le soglie sono state selezionate per ottenere una separazione significativa tra clienti altamente affidabili, profili a rischio intermedio e clienti potenzialmente rischiosi.

I clienti sono stati divisi in tre classi: Low risk, medium risk e High risk, nella prima categoria i clienti sono soggetti a meno controlli e ad un'approvazione veloce, i clienti a rischio medio necessitano verifiche aggiuntive, un monitoraggio e se necessario una revisione manuale, infine i clienti ad alto rischio possono incorrere in un rifiuto o in controlli molto approfonditi. Nel Grafico 3 è rappresentata la distribuzione dei punteggi




Grafico 3- Distribuzione rischio di credito

Le soglie per classificare i clienti sono state: Low risk per punteggi >700, Medium risk per punteggi compresi tra 500 e 700 e High risk per punteggi <500.

La segmentazione risultante ha mostrato pattern coerenti, con il gruppo High Risk contenente una proporzione significativamente più elevata di clienti rischiosi, mentre il segmento Low Risk era dominato da clienti affidabili.




Grafico 4- Risultati segmentazione in confronto con il rischio reale

Il processo di scoring e segmentazione ha trasformato le previsioni grezze del modello in un framework più operativo e orientato al business, migliorando l'interpretabilità e supportando potenziali applicazioni decisionali.

6. Conclusioni

Il progetto ha avuto l'obiettivo di sviluppare un modello di credit risk in grado di stimare l'affidabilità creditizia dei clienti utilizzando tecniche di machine learning e strumenti di business intelligence. Attraverso l'utilizzo del German Credit Dataset è stato possibile costruire un workflow completo comprendente data preparation, preprocessing, modellazione statistica, valutazione delle performance e visualizzazione dei risultati.

Per la fase di modeling è stata utilizzata una Logistic Regression, scelta per la sua interpretabilità e per il largo utilizzo nel settore bancario e finanziario. Il modello ha mostrato performance soddisfacenti, raggiungendo una ROC-AUC di circa 0.80 e una buona capacità di distinzione tra clienti affidabili e clienti rischiosi.

L'analisi delle metriche ha evidenziato come il modello sia particolarmente efficace nell'identificazione dei clienti affidabili, mantenendo comunque una capacità discreta di individuazione dei profili più rischiosi. La fase di threshold tuning ha inoltre permesso di selezionare una soglia decisionale coerente con gli obiettivi di business e con il trade-off tra precision e recall.

Successivamente, le probabilità prodotte dal modello sono state trasformate in un sistema di credit scoring interpretabile, accompagnato da una segmentazione del rischio in tre categorie: Low Risk, Medium Risk e High Risk. Questa trasformazione ha reso i risultati più facilmente leggibili da un punto di vista operativo e maggiormente vicini ai reali sistemi di valutazione utilizzati nel settore finanziario.

Nel complesso, il progetto rappresenta un esempio concreto di integrazione tra data science, analisi statistica e business intelligence applicata al credit risk management.

7. Limitazioni e Possibili Miglioramenti

Nonostante i risultati ottenuti siano stati soddisfacenti, il progetto presenta alcune limitazioni che devono essere considerate nell'interpretazione delle performance del modello.

La principale limitazione riguarda il dataset utilizzato. Il German Credit Dataset contiene solamente 1000 osservazioni ed è stato costruito negli anni '90, risultando quindi relativamente piccolo e parzialmente distante dagli attuali contesti economici e finanziari. Inoltre, alcune variabili possono riflettere caratteristiche storiche o bias socioeconomici non più rappresentativi della realtà moderna. Considerata la dimensione relativamente ridotta del dataset, un approccio basato sulla cross-validation potrebbe fornire stime delle performance del modello più robuste e stabili rispetto ad una singola divisione train-test; tecniche come la k-fold cross-validation permetterebbero di valutare il modello su diverse partizioni dei dati, riducendo la sensibilità al campionamento casuale.

Un ulteriore limite è rappresentato dallo sbilanciamento delle classi, con una prevalenza di clienti affidabili rispetto ai clienti rischiosi. Questa caratteristica rende più complessa l'identificazione dei casi di default e può influenzare alcune metriche di valutazione.

Dal punto di vista modellistico, la Logistic Regression offre elevata interpretabilità ma potrebbe non essere in grado di catturare relazioni non lineari o interazioni complesse tra le variabili. Modelli più avanzati come Random Forest, XGBoost o Gradient Boosting potrebbero potenzialmente migliorare le performance predittive. L'identificazione degli outlier potrebbe inoltre essere migliorata utilizzando metodi basati sull'influenza, come la distanza di Cook, particolarmente adatti ai modelli di regressione e capaci di individuare osservazioni altamente influenti.

Anche la fase di feature engineering potrebbe essere ulteriormente approfondita, ad esempio attraverso la creazione di nuove variabili derivate, trasformazioni non lineari o tecniche più sofisticate di gestione degli outlier e delle variabili categoriche.

Il modello attuale è stato ottimizzato utilizzando la codifica originale del target, dove i clienti "good" erano rappresentati dalla classe 1. Tuttavia, nelle applicazioni reali di credit risk, il principale obiettivo di business è spesso l'identificazione dei clienti rischiosi e dei potenziali default; futuri miglioramenti potrebbero includere una ridefinizione della variabile target al fine di ottimizzare direttamente l'identificazione dei clienti "bad", migliorando potenzialmente recall e F1-score della classe rischiosa. Questo permetterebbe di allineare maggiormente la strategia di modellazione ai costi economici associati alla classificazione errata dei clienti ad alto rischio.

Inoltre, un aspetto particolarmente importante nei sistemi di credit scoring riguarda fairness ed etica. Alcune variabili presenti nel dataset, come `foreign_worker`, possono introdurre bias indesiderati nei processi decisionali automatici. Nei contesti reali, questi aspetti richiedono particolare attenzione sia dal punto di vista normativo sia da quello etico.

Come possibile sviluppo futuro, il progetto potrebbe essere ampliato introducendo modelli ensemble, tecniche di cross-validation più avanzate, ottimizzazione automatica degli iperparametri e sistemi di explainable AI per migliorare ulteriormente interpretabilità e affidabilità delle previsioni.